

Introduction :

En février 2005, trois ex-employés de Paypal créent un site de streaming vidéo qu'ils nomment YouTube. La plateforme est rachetée un an plus tard par Google. En 2009, l'un des fondateurs annonce qu'un milliard de vues sont comptabilisées chaque jour sur YouTube [42]. En 2021, c'est un milliard d'heures de vidéos qui sont consommées par jour avec plus de 2 milliards d'utilisateurs connectés chaque mois, soit plus d'un quart de la population mondiale [43]. Cette audience fait de Youtube l'un des 10 sites les plus fréquentés au monde [20], et donc un acteur central dans la circulation des informations. Aujourd'hui, parmi le milliard d'heures de vidéos consommées par jour, environ 70% sont recommandées par des algorithmes [17]. Ainsi, une grande partie de la décision de faire circuler certaines informations plutôt que d'autres incombe aux algorithmes responsables de la recommandation, développés par les ingénieurs de YouTube. Ces systèmes de recommandations, dont nous expliciterons la définition et le fonctionnement, ont commencé à être mis en place dans l'entreprise en 2011. Un an plus tard, YouTube évoque sur son blog une stratégie visant à maximiser l'engagement de l'utilisateur en recommandant les contenus qui augmentent le temps que le spectateur passe sur la plateforme : "Désormais, lorsque nous suggérons des vidéos, nous nous concentrons sur celles qui augmentent le temps que le spectateur passera à regarder des vidéos sur YouTube [...], cela signifie que les créateurs attirent un public plus engagé¹" [21]. Nous nous demanderons comment YouTube maximise l'engagement des spectateurs, et quelles en sont les conséquences.

Le document est divisé en cinq parties. Nous commencerons par définir ce que sont, et comment fonctionnent les systèmes de recommandation. Cela nous permettra ensuite d'évoquer la littérature sur le fonctionnement technique du système de recommandation spécifique à YouTube. Après avoir analysé la valeur créée par les technologies de recommandation, nous aborderons quelques défis de modération auxquels est confronté YouTube. Enfin, ces enjeux justifient l'importance de la transparence et de la régulation. La dernière partie abordera ce sujet sous le prisme de la réglementation européenne et chinoise.

¹ Traduit de l'anglais : Now when we suggest videos, we focus on those that increase the amount of time that the viewer will spend watching videos on YouTube, not only on the next view, but also successive views thereafter.

If viewers are watching more YouTube, it signals to us that they're happier with the content they've found. It means that creators are attracting more engaged audiences.

- 1. Fonctionnement des systèmes de recommandations**
 - 1.1 Typologie des systèmes de recommandation
 - 1.2 Application d'un système de recommandation collaborative-filtered
 - 1.3 Application d'un système de recommandation content-based
- 2. Fonctionnement du système de recommandations de YouTube**
 - 2.1 Présentation du système de recommandation YouTube
 - 2.2 Un système de recommandation des plus sophistiqués
 - 2.3 Focus sur le Up Next Panel
- 3. Valeur créée par les systèmes de recommandations**
 - 3.1 La valeur perçue par l'utilisateur
 - 3.2 La valeur économique des RS
- 4. La difficile modération des plateformes**
 - 4.1 Le sensationnalisme stimulerait l'engagement des utilisateurs
 - 4.2 Le conspirationnisme, et les echo chambers sur YouTube
 - 4.3 La modération de YouTube
- 5. Transparence et Régulation**
 - 5.1 La régulation européenne des services en ligne
 - 5.2 Le projet européen de régulation sur les systèmes de recommandation
 - 5.3 La régulation chinoise des systèmes de recommandation

1. Fonctionnement des systèmes de recommandations

Le logiciel qui détermine quelles vidéos suggérer à un utilisateur est un *system recommender*. Ce logiciel fait des recommandations personnalisées. Autrement dit, chaque utilisateur aura des vidéos différentes dans ses propositions, adaptées à ses goûts. Le *recommender system* tente de prédire l'évaluation que ferait un utilisateur d'un objet (un livre, de la musique, un film, une vidéo...) sans qu'il n'ait encore considéré cet objet.

Les recommandations personnalisées nécessitent en amont d'avoir des informations sur l'utilisateur. Chaque système de recommandation stocke et alimente un profil utilisateur, qui contient par exemple les préférences ou l'historique. Le *system recommender* de YouTube retiendra en mémoire les vidéos précédemment regardées pour pouvoir estimer quelles autres vidéos pourraient intéresser l'utilisateur. Si le profil utilisateur est présent dans tous les *recommender systems*, la manière dont les informations sont récupérées et traitées différera selon la technique de recommandation [1]. Intéressons-nous aux différentes approches possibles pour créer un système de recommandation.

1.1 Typologie des systèmes de recommandation

L'approche *collaborative-filtering* : le principe de base de cette approche repose sur l'hypothèse que si deux utilisateurs ont eu des goûts très proches dans le passé, ils continueront à aimer les mêmes choses dans le futur. Ainsi, si l'utilisateur A et l'utilisateur B aiment souvent les mêmes vidéos, et que A a beaucoup aimé cette vidéo que B n'a pas vue, B a de grandes chances d'aimer cette vidéo. D'où, le *system recommender* (SR) à méthode collaborative filtrera cette vidéo comme pertinente et la recommandera à B. Dans cette approche, le système de recommandation n'a pas besoin de connaître le contenu de la vidéo. La question principale est alors : Comment mesurer la similarité entre les profils ?

L'approche *content-based* : si les SR peuvent permettre à un utilisateur de regarder une vidéo en particulier, ils peuvent aussi permettre la sélection d'une vidéo pertinente parmi une large base de données de vidéos. Les SR sont particulièrement utiles pour classer et filtrer un grand nombre de contenus, notamment grâce aux informations dérivées des contenus à classer. Ainsi les systèmes de recommandation à approche *content-based* nécessitent d'avoir des informations dérivées des contenus et d'avoir assigné une importance, ou une valeur à ces différentes informations. Ainsi, si je sais que l'utilisateur A aime les vidéos d'informatique, mais n'aime pas les tutoriels, et que les informations de la vidéo 1, notamment le titre de la vidéo, montre qu'il s'agit d'une vidéo informatique, mais que le tag "tutoriel" n'est pas présent, alors il est possible que l'utilisateur A aime cette vidéo. La question principale est alors : Comment extraire les informations des contenus et affiner les profils utilisateurs ?

L'approche *knowledge-based* : dans certains cas, la plupart des utilisateurs n'ont pas de profil, ou n'utilisent que rarement un service, par exemple lors d'un achat ponctuel tel que pour une caméra. Cette situation rend inefficace les deux approches précédemment évoquées, puisque le SR n'a pas de profils utilisateurs similaires et ne connaît pas les préférences de l'utilisateur pour faire les recommandations *content-based*. Le *recommender system* à approche *knowledge-based* utilise de la connaissance souvent complétée par des informations fournies manuellement par l'utilisateur. Par exemple, si l'utilisateur souhaite

acheter une caméra destinée à faire du cinéma, il convient de lui recommander une caméra reflex avec des réglages de luminosité plutôt qu'un caméscope aux réglages limités. La question principale est alors : Comment connaître les préférences d'un utilisateur lorsqu'il n'a pas de profil utilisateur et quelles connaissances intégrer à la base de données ?

Les méthodes hybrides : chaque approche précédemment évoquée est adaptée à certaines problématiques et présente des qualités et défauts, et parfois la combinaison de plusieurs approches peut permettre de maximiser la pertinence des recommandations. Prenons l'exemple de la combinaison de l'approche collaborative et content-based. Si l'utilisateur B, similaire à l'utilisateur A, a particulièrement apprécié deux vidéos qui n'ont pas encore été vues par A, et que, l'une de ces vidéos traite d'informatique. Sachant que le profil utilisateur de A montre que A aime tout particulièrement les vidéos informatiques, il sera encore plus pertinent de recommander la vidéo traitant d'informatique.

Après avoir abordé les différentes approches pour créer un système de recommandation, prenons l'exemple d'une application d'un système de recommandation collaborative-filtering.

1.2 Application d'un système de recommandation collaborative-filtering

Prenons l'exemple d'un recommender system collaborative-filtering. D'abord, les interactions entre les utilisateurs et les objets (*item* en anglais, ici les films) sont stockées dans la matrice d'interactions *user-item* (par exemple, la matrice peut contenir les notes que les utilisateurs ont mis à un film, voir Figure 1). Ensuite, l'objectif est de faire des prédictions d'*item* pertinentes pour un utilisateur donné. Pour faire ces prédictions *collaborative-filtering*, différentes méthodes existent telles que les méthodes *user-user*, *item-item* ou la factorisation de matrice. Prenons l'exemple de l'approche *user-user*.

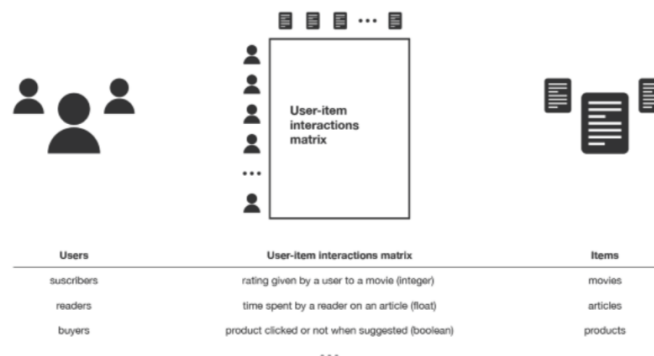


Figure 1 : Vue d'ensemble de la matrice user-item [13]

Dans l'approche *user-user*, le RS va faire une nouvelle recommandation à un utilisateur en identifiant les utilisateurs ayant un profil similaire (les plus proches voisins), et en recommandant les items que ces utilisateurs aiment. Tout d'abord, chaque utilisateur peut être représenté par son vecteur d'interactions avec les différents items ("sa ligne" dans la matrice d'interaction, voir Figure 2). Ensuite, nous pouvons calculer une sorte de "similarité" entre notre utilisateur et tous les autres utilisateurs. Cette mesure de similarité est telle que deux utilisateurs ayant des interactions similaires sur les mêmes items doivent être considérés comme proches. Une fois que les similarités avec chaque utilisateur ont été

calculées, nous pouvons conserver les k-plus proches voisins de notre utilisateur, puis suggérer les éléments les plus populaires (que notre utilisateur n'a pas encore vus) parmi ces k-plus proches voisins.



Figure 2 : Vue d'ensemble d'approche user-user [13]

1.3 Application d'un système de recommandation content-based

Ensuite, prenons l'exemple d'un *recommender system* de films basé cette fois sur une approche content-based. Le SR utilise des informations sur l'utilisateur tels que : l'âge, le sexe, le travail et autres (*user features*). Mais il utilisera également des informations sur l'*item* tels que la catégorie de film, les acteurs principaux, la durée, et autres (*item features*). L'objectif du RS est alors d'essayer de construire un modèle basé sur les informations disponibles, qui explique les interactions utilisateur-item observées. Par exemple, le SR de films peut modéliser que les jeunes femmes ont tendance à mieux noter certains films, que les jeunes hommes ont tendance à mieux noter certains autres films, etc. Ainsi, par la suite le modèle pourra faire des prédictions pour un utilisateur en regardant son profil (âge, sexe, etc.) et ainsi déterminer les films pertinents à recommander.



Figure 3 : Vue d'ensemble d'une approche content-based [13]

On peut noter que, selon la complexité de la relation à exprimer, le modèle à construire peut être plus ou moins complexe, allant des modèles de base (logistique/régression linéaire pour la classification/régression) aux réseaux de neurones (*deep neural networks*).

Finalement, nous avons constaté que le logiciel à l'origine des recommandations personnalisées est appelé *recommender system*. Nous avons vu que plusieurs approches existent pour prédire l'évaluation que ferait un utilisateur d'un objet sans qu'il n'ait encore considéré cet objet : *collaborative-filtering*, *content-based*, *knowledge-based*, et les méthodes hybrides. Afin de mieux percevoir les modes de fonctionnement de ces approches nous avons évoqué plus en détail l'approche *collaborative-filtering*. Pour cela, nous avons abordé la façon dont un RS peut recommander un contenu via la méthode *user-user*. Puis pour en distinguer un autre moyen de faire des recommandations, nous avons évoqué plus en détail l'approche *collaborative-filtering* au travers d'un exemple d'un RS de films. Abordons maintenant le fonctionnement du *recommender system* de YouTube.

2. Fonctionnement du système de recommandations de YouTube

Comme indiqué dans le document *Comment YouTube recommande vos vidéos* [14] : “le système de recommandation de YouTube trouve des vidéos adaptées à chaque spectateur, plutôt que des spectateurs pour chaque vidéo”. Intéressons-nous donc à ce que l'on sait sur comment YouTube trouve des *items* pour ses utilisateurs.

2.1 Présentation du système de recommandation de YouTube

D'abord, il convient d'expliquer où YouTube fait ses recommandations, et quelles sont les communications de l'entreprise sur ce sujet. La plateforme recommande des vidéos à deux endroits distincts (voir Figure 4) : la homepage et le Up next panel. Pour le premier, qui est la page d'accueil, YouTube explique qu'il s'agit d'un mélange de contenu personnalisé, d'abonnements, et des actualités et informations récentes : “it displays a mixture of personalized recommendations, subscriptions, and the latest news and information” [12]. Pour le second, qui s'affiche lorsque l'on est déjà en train de regarder une vidéo, YouTube explique que c'est du contenu additionnel basé sur ce que l'on est actuellement en train de regarder ou du contenu susceptible de nous plaire : “suggests additional content based on what you're currently watching, alongside other videos that we think you may be interested in” [12].

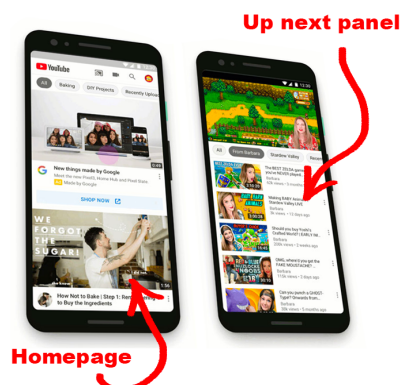


Figure 4 : La homepage et le Up next panel

YouTube s'est exprimé sur son recommander system principalement dans son article *On YouTube's recommendation system* [12] : "trop souvent, les recommandations sont perçues comme une mystérieuse boîte noire. Nous voulons que ces systèmes soient compris du public, alors laissez-moi vous expliquer comment ils fonctionnent". Dedans, la plateforme évoque une approche collaborative, "Our system compares your viewing habits with those that are similar to you and uses that information to suggest other content you may want to watch, So if you like tennis videos and our system notices that others who like the same tennis videos as you also enjoy jazz videos, you may be recommended jazz videos, even if you've never watched a single one before". Elle y aborde également, comme dans plusieurs autres documents [14] l'évolution de son système de recommandation dans le temps, avec notamment trois dates clés : 2011, 2012, et 2015, qui correspondent respectivement à l'époque avant l'intégration de la métrique watchtime, à l'intégration du watchtime, et enfin à l'intégration des enquêtes de satisfaction. C'est à partir de 2008 la plateforme développe son système de recommandation. Jusqu'alors, les vidéos sont recommandées selon leur popularité (c'est-à-dire selon les clics) sur l'ensemble des utilisateurs et la plupart des vidéos regardées ont été trouvées via une recherche ou des liens externes à la plateforme. En 2011, les employés de YouTube comprennent qu'un important nombre de clics ne signifie pas que la vidéo est vraiment regardée : "si je cherche les temps forts d'un match, je fais défiler la page et clique sur l'une des vidéos, qui a une vignette et un titre suggérant qu'elle montre des images du match. Au lieu de cela, c'est une personne dans sa chambre qui parle du match. Et vous cliquez sur une autre vidéo encore et encore, jusqu'à ce que l'on vous recommande enfin une vidéo avec des images du match que vous souhaitez regarder" [12]. Ainsi, le watchtime, c'est-à-dire le temps de vidéo regardé, est ajouté en 2012. En effet, la métrique permet de mieux comprendre les besoins de ses utilisateurs : "Si je regarde 20 secondes de la personne dans sa chambre, mais 5 minutes des temps forts du match, on comprend que ce qui m'intéresse, ce sont les images des matchs". Puis en 2015, YouTube intègre les enquêtes de satisfaction, avec cette justification : "tous les temps de visionnage ne sont pas égaux. Parfois, je me suis levé tard, et je regarde des vidéos au hasard, alors que j'aurais pu plutôt apprendre une nouvelle langue sur YouTube [...] Nous ne voulons pas que les spectateurs regrettent les vidéos qu'ils passent du temps à regarder et ont réalisé que nous devons faire encore plus pour mesurer la valeur que vous tirez de votre temps sur YouTube". Les enquêtes de satisfaction proposent à l'utilisateur de noter de 0 à 5 étoiles une vidéo regardée. Même si tous les utilisateurs n'y répondent pas forcément, YouTube utilise un modèle d'apprentissage automatique qui prévoit la réponse d'un utilisateur à cette question, et adapte le modèle selon l'erreur de prédiction. Maintenant que nous avons présenté le RS de YouTube, intéressons-nous à son fonctionnement technique.

2.2 Un système de recommandation des plus sophistiqués

Trois ingénieurs de YouTube, Paul Covington, Jay Adams, et Emre Sargin, publient en 2016 l'un des textes fondateurs sur le fonctionnement du système de recommandation de YouTube : *Deep Neural Networks for YouTube Recommendations* [2]. Dans cet article, les auteurs montrent l'importance du Deep Learning dans la personnalisation des recommandations : "YouTube has undergone a fundamental paradigm shift towards using

deep learning as a general-purpose solution for nearly all learning problems”. On y apprend donc que l’entreprise a intégré le deep learning dans presque tous les problèmes d’apprentissage, et notamment que le recommender system est construit sur leur propre outil de machine learning, devenu entre-temps open-source, TensorFlow. Grâce à cet outil les ingénieurs peuvent depuis des années déjà expérimenter de nombreuses architectures de neurones : “TensorFlow provides a flexible framework for experimenting with various deep neural network architectures” [2]. Rappelons que l’utilisation de réseaux de neurones est une technique qui fait partie du domaine de l’intelligence artificielle, et plus particulièrement du deep learning. Le réseau de neurones, qui est constitué de plusieurs couches, permet de faire des prédictions. Pour cela, on développe un modèle, puis à partir d’un dataset on l’entraîne. On peut par exemple avoir un dataset qui fait des correspondances entre les inputs et les outputs (*supervised learning*). La première couche de notre réseau de neurones reçoit alors les inputs. Les informations passent de couches en couches, jusqu’à la couche qui renvoie l’output. On entraîne le modèle jusqu’à ce qu’il soit capable de trouver les outputs corrects. Dans le cas du recommender system de YouTube, on distingue deux réseaux de neurones : l’un est utilisé pour la génération de candidats (*items*, ici les vidéos) et l’autre pour le classement de ces candidats (Figure 5).

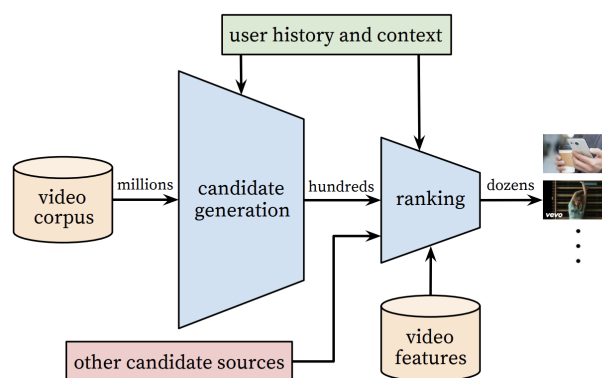


Figure 5 : Architecture du système de recommandation où les vidéos candidates sont récupérées et classées avant de n'en présenter que quelques-unes à l'utilisateur [2].

Comme illustré dans la Figure 5, le réseau de neurones qui sert à générer les candidats prend en input l'historique de l'utilisateur et le corpus de vidéos YouTube (composé de millions de vidéos), et renvoie en output un petit sous-ensemble de quelques centaines de vidéos. Ce sous-ensemble est composé des vidéos les plus pertinentes à recommander à l'utilisateur. Les auteurs s'expriment "The candidate generation network only provides broad personalization via collaborative filtering. The similarity between users is expressed in terms of coarse features such as IDs of video watches, search query tokens and demographics". Nous comprenons donc que le réseau de neurones *candidate generation* repose sur une approche *collaborative-filtering* avec des user-features telles que l'ID des vidéos regardées, les recherches effectuées et les données démographiques. Le second réseau de neurones va lui attribuer une note à chaque vidéo sélectionnée dans le sous-ensemble selon une fonction définie à partir de plus d'une centaine de features du *user* et de l'*item*. Les vidéos les mieux notées sont alors recommandées à l'utilisateur.

Les ingénieurs insistent également sur la sophistication du recommender system de YouTube. D'abord, les modèles de génération de candidat et de classification sont améliorés dans le temps puisqu'ils sont entraînés et corrigés via des tests en ligne et hors ligne : "During development, we make extensive use of offline metrics to guide iterative improvements to our system. [...] we rely on A/B testing via live experiments. In a live experiment, we can measure subtle changes in click-through rate, watch time, and many other metrics that measure user engagement"[2]. Et pour pouvoir mesurer ces subtiles changements évoqués par les ingénieurs sur des métriques telles que le watchtime ou le *click-through rate* YouTube en collecte les données. Ces données sont en nombre particulièrement important, puisque les systèmes de YouTube analysent aujourd'hui plus de 80 milliards de signaux par jour (vidéos regardées, vidéos non regardées, lieu de visionnage, heure de visionnage, partages, etc, voir Figure 6) [14]. Les signaux sont récupérés depuis des années. En effet, en 2010 déjà, d'autres ingénieurs de YouTube publiaient l'article *The YouTube Video Recommendation System* [15], dans lequel un recommender system en deux étapes, génération de candidats et classification, est déjà évoqué.

Confidentialité et propriété

Chaque jour, nos systèmes analysent plus de 80 milliards de signaux provenant des spectateurs

- Vidéos regardées
- Vidéos non regardées
- Durée de visionnage
- Lieu de visionnage
- Heure de visionnage
- "J'aime" et "Je n'aime pas"
- Partages
- Commentaires "Pas intéressé"
- Enquêtes réalisées avant et après le visionnage
- Et plus encore

Google YouTube

Figure 6 : Quelques signaux récupérés par YouTube

Ensuite, la sophistication résulte aussi de contraintes provoquées par un environnement très complexe. L'une d'elles évoquée par les ingénieurs est l'échelle particulièrement importante du corpus de vidéos et du nombre d'utilisateurs : "Many existing recommendation algorithms proven to work well on small problems fail to operate on our scale". Le modèle de sélection de candidats doit également faire face à un corpus de vidéos en constante modification, avec de nouvelles vidéos téléchargées toutes les secondes, ainsi qu'à des facteurs externes non observables dans les données. En effet, la satisfaction des utilisateurs est principalement déduite de données implicites (sauf lors des rares réponses aux sondages), ce qui laisse place à beaucoup d'imprécisions sur les données. Intéressons-nous désormais plus en détail au Up Next Panel, et notamment au fonctionnement de son réseau de neurones de classement.

1.5 Focus sur le Up Next Panel

L'article *Recommending What Video to Watch Next: A Multitask Ranking System* est un document écrit par d'autres ingénieurs de YouTube en 2019 [3]. Ils y proposent une solution pour améliorer la recommandation de la prochaine vidéo à regarder faite par YouTube dans

le Up next panel. Intéressons-nous à cette proposition afin d'entrevoir des exemples de défis technologiques auxquels doivent faire face les ingénieurs de YouTube dans la mise en place de leur système de recommandation.

On peut distinguer deux étapes principales dans le fonctionnement d'un système de recommandation, comme évoqué précédemment [3]. La première étape permet de générer des candidats (vidéos) qu'il peut être pertinent de recommander à l'utilisateur. Au cours de cette étape, plusieurs algorithmes génèrent ces candidats en prenant en compte le contenu de la vidéo regardée et le profil utilisateur. Par exemple, l'un des algorithmes peut générer des vidéos candidates ayant le même sujet que la vidéo actuellement regardée. A la fin, quelques centaines de vidéos candidates demeurent. La seconde étape est de classer ces vidéos. L'article ne donne pas plus de détails sur la première partie et décide de se concentrer sur la seconde partie en proposant un système de classement (*ranking system*) à grande échelle. Ce système repose sur une nouvelle architecture de réseau de neurones, destiné à recommander une vidéo qui sera appréciée par l'utilisateur, en prenant en compte la vidéo qu'il est actuellement en train de regarder et ses données utilisateur.

Les auteurs soulignent deux défis majeurs à cette recommandation. Le premier défi est qu'il y a plusieurs objectifs de classement (*ranking*) concurrents. Ces objectifs sont traduits dans des fonctions objectif. Une fonction objectif est une fonction qui sert de critère pour déterminer la meilleure solution à un problème d'optimisation [3]. Dans notre cas, les objectifs sont à la fois des objectifs d'engagement de l'utilisateur (nombre de clics, degré d'engagement), et des objectifs de satisfaction (partages, commentaires). Le second défi est la nécessité de supprimer les biais implicites, qui sont contenus dans les données utilisées pour l'entraînement du modèle. Par exemple, il est possible qu'un utilisateur ait pu cliquer et regarder une vidéo simplement parce qu'elle était bien classée (en haut du classement), et non pas parce que c'est la vidéo qu'il préférerait. Ainsi, si le modèle est formé à l'aide de ces données biaisées, il produira des recommandations non optimales. Pour relever ces deux défis, les chercheurs ont conçu l'architecture de réseau de neurones de la Figure 7. Dans cette architecture, le modèle prédit deux catégories de comportements des utilisateurs : l'engagement et la satisfaction (*User Engagement Objectives*, *User Satisfaction Objectives* sur la Figure 7). Puis ces prédictions multiples sont combinées dans un score de classement final (*Ranking score*). L'output du réseau de neurone est ce score de classement. Les inputs sont dans la première couche du bas, en jaune pour les features et en violet pour les *embeddings* (ce sont des vecteurs de nombres réels qui représentent des mots ou phrases). Dans cette architecture, le premier défi est géré dans l'encadré rouge, tandis que le second est géré dans l'encadré bleu. Intéressons-nous à la gestion du second problème, celui des biais dans les données.

Les données idéales pour former un système de recommandation seraient des données directement fournies par l'utilisateur (ou *explicit feedback data*) indiquant s'il aime ou non la recommandation faite (tel que les enquêtes de satisfaction). Ces données étant coûteuses à collecter (les enquêtes sont rarement proposées et peu souvent remplies), l'entraînement se fait principalement sur des données implicites (*implicit feedback*). Ainsi, si l'utilisateur clique sur une recommandation, on considère qu'elle lui plaît. Mais comme évoqué précédemment, ça n'est pas toujours vrai, ce qui constitue un biais dans les données. Ce biais doit être supprimé lors de la formation du modèle. Pour cela, une *shallow tower* est introduite dans l'architecture du modèle (en bleu à gauche sur la Figure 7). Une *shallow tower* est un type

de réseau de neurones avec peu de couches (une ou deux), entre la couche input et la couche output. La *shallow tower* est entraînée à l'aide de caractéristiques qui contribuent au biais (*features for selection bias such as click position*, en jaune) tel que la position de la recommandation dans la liste du Up next panel. Elle tente de prédire s'il existe un composant de biais impliqué dans l'instance actuelle. L'output de la shallow tower est utilisé pour entraîner le modèle afin qu'il apprenne à supprimer les biais.

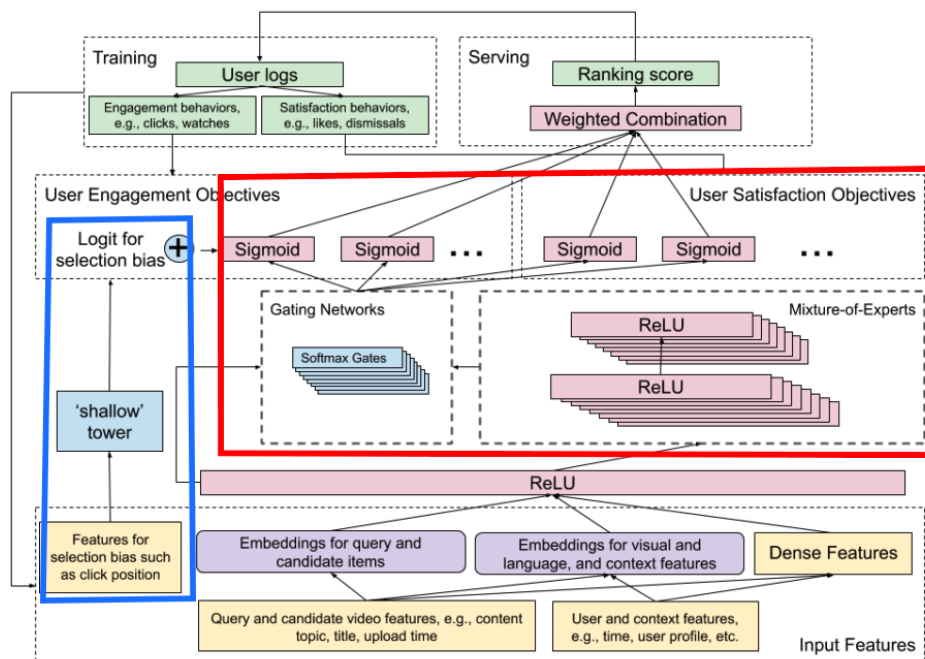


Figure 7 : Architecture du réseau de neurones du ranking system proposé par les auteurs [3]

Finalement, nous avons présenté les deux endroits où apparaissent les recommandations de vidéos : la Homepage et le Up next panel. Pour y faire ses recommandations, le RS repose sur des techniques de deep learning via l'outil TensorFlow. Deux étapes se distinguent dans ce processus : la génération des candidats et le classement de ces candidats. Le RS s'est amélioré depuis sa création en 2008, notamment via des tests permis par un nombre particulièrement important de données collectées. Mais pour maintenir et améliorer ce RS, les ingénieurs de YouTube doivent faire face à un environnement complexe de trois points de vue : l'échelle, le corpus de vidéos en constante modification, et les facteurs externes non observables qui provoquent du bruit (imprécision des données). En résulte un RS particulièrement sophistiqué, dont nous avons pu aborder quelques problématiques techniques avec le *ranking system* du Up next panel. Nous l'avons compris, les *recommender systems* reposent sur diverses approches et technologies dans le but de déterminer quelles vidéos suggérer à un utilisateur en particulier. Il convient maintenant d'étudier quelle est la valeur créée par une telle personnalisation.

3. Valeur créée par les systèmes de recommandations

Le meilleur moyen de maximiser l'engagement d'un spectateur semble être de lui proposer des contenus qui lui sont personnalisés. En effet, un utilisateur passera plus de temps sur YouTube si on lui recommande des vidéos adaptées à ses goûts. De plus, l'augmentation de la quantité d'informations et ressources disponibles sur internet a créé une difficulté à trouver les bonnes informations et faire des choix. YouTube s'est exprimé "Think about how hard it would be to navigate all of the books in a massive library without the help of librarians"[12]. Cela a favorisé le développement des systèmes de recommandation, qui sont aujourd'hui très développés : 80% des heures diffusées sur Netflix sont dûes aux recommandations, 35% des achats faits sur Amazon proviennent de recommandations, et 70% du contenu consommé sur YouTube vient des recommandations [17]. Mais si trouver un contenu personnalisé parmi un grand corpus de vidéos semble être utile, maximiser l'engagement en recommandant des vidéos personnalisées ne signifie pas forcément qu'une plus grande utilité sera perçue par l'utilisateur. L'objectif est ici de comprendre et quantifier la valeur créée par les systèmes de recommandation pour les utilisateurs et pour les entreprises.

3.1 La valeur perçue par l'utilisateur

Les systèmes de recommandation sont extrêmement répandus chez les big tech comme dans les plus petites entreprises. Mais peu de littérature explique comment la valeur pour les utilisateurs est créée par ces systèmes. Le document *Recommender systems and the value of user data* [8] a tenté de quantifier cette valeur et en comprendre ses sources. D'abord, l'auteur décompose le processus de création de valeur en distinguant trois composantes clés : la personnalisation, la sélection et le filtrage. La personnalisation contribue à créer de la valeur en segmentant les utilisateurs en groupes de feedbacks similaires. La deuxième composante de création de valeur consiste à sélectionner le meilleur item selon les segments précédemment définis. Enfin, le filtrage élimine les items jugés non adaptés au groupe. Mais selon l'auteur, la valeur issue de ce processus varie selon différents critères.

- le nombre de *target items* (par exemple nombre vidéos pas encore vues par l'utilisateur) disponibles pour l'utilisateur.
- le nombre d'utilisateurs à partir desquels les données sont collectées. L'auteur évoque qu'intuitivement on estime que les données d'une base d'utilisateurs plus large améliorent l'apprentissage de la structure de corrélation entre les items.
- le nombre d'*items* pris en compte dans la prédiction.
- le seuil de probabilité que l'item plaise retenu pour formuler des recommandations. Ce seuil défini par l'entreprise représente le degré de désalignement entre les intérêts de la plateforme et de l'utilisateur.

L'objectif est de quantifier empiriquement comment ces critères influencent l'utilité perçue par l'utilisateur.

Pour cela, l'auteur a développé un recommender system de blagues. Ce système doit recommander une blague à un user, selon l'approche collaborative filtering. Pour cela, le RS prend en compte une base de données recensant plus de quatre millions de blagues notées par plus de 73 421 utilisateurs. Le RS doit donc sélectionner un item (une blague) avec la probabilité estimée la plus élevée qu'elle plaise à un utilisateur, mais la recommandation ne

se fait que si la probabilité est supérieure à un certain seuil. Pour chaque blague recommandée, l'auteur a évalué la valeur perçue pour les utilisateurs selon 3 cas.

- cas 1 : l'utilisateur a essayé la blague sans recevoir aucune information d'un système de recommandation
- cas 2 : l'utilisateur a décidé d'essayer la blague après avoir examiné la note moyenne de la blague en question
- cas 3 : l'utilisateur a décidé d'essayer la blague suivant les recommandations personnalisées du système

On peut distinguer trois résultats. D'abord, l'auteur observe une augmentation de 132,4% de la valeur d'usage perçue par l'utilisateur (utilité) lors du passage du cas 1 au cas 2, et une augmentation de 7,8 % lors du passage du cas 2 au cas 3. Ces augmentations montrent que plus les recommandations sont personnalisées, plus la valeur perçue par l'utilisateur est grande. L'auteur constate ainsi un effet de réseau positif dans lequel une personnalisation supplémentaire, c'est-à-dire une segmentation plus fine des utilisateurs, augmente toujours (faiblement) la valeur pour les utilisateurs (Figure 8)[8]. Néanmoins, l'utilisateur constate qu'une condition nécessaire pour que la valeur marginale de la personnalisation soit strictement positive est que le niveau de seuil (le seuil minimal de probabilité que l'item plaise à l'utilisateur évoqué ci-dessus) soit choisi de manière optimale. En effet, lorsque le seuil n'est pas aligné sur l'intérêt des utilisateurs il est possible que plus de personnalisation nuise strictement aux utilisateurs.




Figure 8 : Utilité moyenne des utilisateurs à différents degrés de personnalisation [8]

Ensuite, l'auteur constate que la valeur des données de l'utilisateur augmente de 30,4% en passant du cas 1 au cas 2, et de 33,7% en passant du cas 2 au cas 3. En effet, plus les recommandations sont personnalisées, plus la valeur des utilisateurs (qui produisent les données) augmente. L'auteur explique également que la valeur marginale pour un nouvel utilisateur qu'il y ait davantage d'autres utilisateurs du recommander system (pour entraîner le système) est toujours positive mais diminue, formant ainsi un effet de réseau positif décroissant. Enfin, la valeur ajoutée d'un RS pour un utilisateur est encore plus importante lorsque les systèmes de recommandation peuvent choisir parmi plusieurs *target items*. La Figure 9 montre la valeur marginale perçue par les utilisateurs de *target items* supplémentaires. On peut voir que la plus grande disponibilité d'items pour l'étape de la

sélection permet au système de trouver plus facilement des meilleurs items pour les utilisateurs. Néanmoins, l'avantage marginal provoqué par un *target item* supplémentaire parmi lesquels choisir diminue à mesure que davantage d'items deviennent disponibles pour la sélection.




Figure 9 : Utilité moyenne des utilisateurs selon le nombre de *target items* [8]

3.2 La valeur économique des RS

Dans un rapport sur le système de recommandation de Netflix [32], des auteurs révèlent que le RS a grandement contribué à réduire le taux de désabonnement des clients au cours du temps. En conséquence, les auteurs estiment la valeur commerciale de la recommandation à plus d'un milliard de dollars américains par an. Si la valeur commerciale du RS de Netflix est évoquée, peu d'articles et publications montrent en détail l'influence qu'ont les systèmes de recommandation sur le profit des entreprises. L'auteur de *Measuring the Business Value of Recommender Systems* [17] s'exprime : "Companies usually do not publicly share the exact details about how they profit from the use of recommendation technology". Pourtant, un nombre important d'articles [18], [15], [19] montrent que les systèmes de recommandation peuvent en effet avoir divers effets commerciaux positifs.

Notons que la manière dont les entreprises peuvent mesurer ces effets commerciaux, notamment au travers de certaines métriques, varient selon les domaines d'activité et business-modèles. Par exemple, dans le cas des e.commerces, les objectifs sont soit de promouvoir directement les ventes par le biais du recommandeur, soit d'obtenir des changements dans le comportement d'achat des consommateurs, par exemple vers des articles plus rentables [17]. De son côté, YouTube a un business-modèle basé sur deux types de revenus. Le premier est la publicité, qui consiste en la diffusion de différents types d'annonces sur les vidéos, ainsi que de bannières. Pour toutes les publicités affichées sur les pages de visualisation du contenu des créateurs, YouTube récupère 45 % des revenus nets. Le second revenu non cumulatif au premier est tiré de l'abonnement (YouTube Premium, YouTube Music) qui n'affiche pas les publicités, pour lequel YouTube récupère à nouveau 45% des revenus nets générés à partir du temps de visionnement du contenu de créateurs. Mais parmi ces deux sources de revenu, l'entreprise rappelle que la source principale est la publicité [23]. Ainsi, plus les utilisateurs passent du temps sur YouTube, plus le chiffre d'affaires de l'entreprise augmente. Or, comme évoqué précédemment, les

systèmes de recommandation permettent d'augmenter la valeur perçue par l'utilisateur, et donc de maximiser le temps passé par l'utilisateur sur la plateforme. D'où, l'entreprise oriente les objectifs de son système de recommandation, comme évoqué dans l'introduction, vers l'engagement : "Now when we suggest videos, we focus on those that increase the amount of time that the viewer will spend watching videos on YouTube, not only on the next view, but also successive views thereafter [...] It means that creators are attracting more engaged audiences. It also opens up more opportunities to generate revenue for our partners". Les effets commerciaux du système de recommandation de YouTube sont donc évaluables selon la capacité du RS à maximiser le temps que l'utilisateur passe sur la plateforme. En 2010, les ingénieurs de YouTube évoquent certaines métriques permettant d'évaluer la qualité du recommandation du système : "we use a combination of different metrics [...] click through rate (CTR), long CTR (only counting clicks that led to watches of a substantial fraction of the video), session length, time until first long watch, and recommendation coverage (the fraction of logged in users with recommendations)" [15].

Finalement, nous avons observé qu'une personnalisation supplémentaire, c'est-à-dire une segmentation plus fine des utilisateurs, augmente toujours la valeur pour les utilisateurs, à condition que le niveau de seuil choisi soit optimal. Nous avons également vu que la valeur marginale pour un nouvel utilisateur qu'il y ait davantage d'autres utilisateurs du recommander system est toujours positive mais diminue. Et également que la plus grande disponibilité d'*items* pour l'étape de la sélection permet au système de trouver plus facilement des meilleurs items pour les utilisateurs. Enfin, nous avons vu que YouTube base son revenu sur les publicités et l'abonnement, d'où son objectif de maximiser le temps que passe l'utilisateur sur la plateforme. Sachant que le RS permet d'augmenter l'utilité perçue par l'utilisateur, et donc son temps passé sur la plateforme, on peut conclure que le RS et le chiffre d'affaires de YouTube sont interdépendants. Mais si les RS permettent de créer de la valeur en personnalisant les recommandations, ils ont aussi une responsabilité quant au contenu recommandé. Intéressons-nous au contenu que proposent les *recommender systems*.

4. La difficile modération des plateformes

En 2018, Mark Zuckerberg s'est exprimé : "The past two years have shown that without sufficient safeguards, people will misuse these tools to interfere in elections, spread misinformation, and incite violence. One of the most painful lessons I've learned is that when you connect two billion people, you will see all the beauty and ugliness of humanity" [5]. Comme Facebook, YouTube connecte des milliards de spectateurs à des millions de créateurs avec plus de 500 heures de vidéos uploadées chaque minute, ce qui représente plus de 82 ans de vidéos uploadées par jour. Parmi ces contenus, comme évoqué par le créateur de Facebook, se trouvent des propos favorisant la désinformation ou incitant à la violence. Or, avec deux milliards d'utilisateurs actifs mensuel, la conception du *recommender system* de YouTube a plus d'impact sur la circulation de l'information que les rédactions des médias traditionnels [11]. Dans un tel contexte, le contenu qui peut être recommandé par le RS de YouTube doit être modéré, ce qui pose des problèmes.

4.1 Le sensationnalisme stimulerait l'engagement des utilisateurs

Mark Zuckerberg a écrit une série de notes évoquant les défis majeurs auxquels est confronté Facebook et les progrès réalisés. *A Blueprint for Content Governance and Enforcement* [5] est la seconde note de la série. Dans ce document, le fondateur de Facebook dit que plus un contenu est borderline, plus l'engagement des utilisateurs augmente : "One of the biggest issues social networks face is that, when left unchecked, people will engage disproportionately with more sensationalist and provocative content". Selon les recherches faites par Facebook, lorsqu'un contenu s'approche de la limite du contenu non autorisé, les gens sont en moyenne davantage engagés, peu importe où la limite est tracée, et ce, même s'ils disent après ne pas avoir aimé le contenu (Figure 10). Mark Zuckerberg ajoute que ce modèle naturel de contenu borderline obtenant plus d'engagement s'applique aux actualités comme à presque toutes les autres catégories de contenu. Il explique que les photos proches de la ligne de nudité, comme avec des vêtements révélateurs ou des positions sexuellement suggestives, ont obtenu plus d'engagement en moyenne que les contenus plus éloignés de la limite. Le constat est le même pour les messages qui ne relèvent pas directement du discours de haine, au sens défini par Facebook, mais qui sont tout de même offensants.

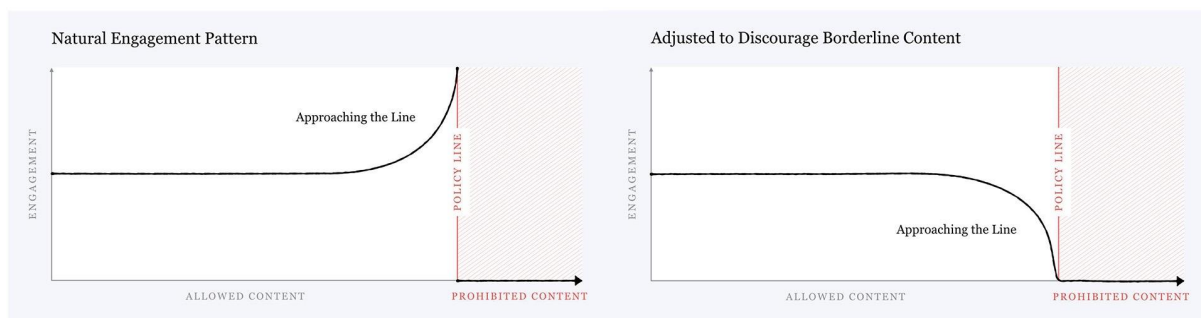



Figure 10 et 11 : engagement naturel des utilisateurs avec et sans ajustement mis en place par Facebook [5]

De son côté, le Chief Product Officer de YouTube, Neal Mohan, défend que les contenus extrêmes ne favorisent pas forcément l'engagement : "It is not the case that "extreme" content drives a higher version of engagement or watchtime than content of other types." [24]. Malgré ces déclarations, et étant donné que le système de recommandation de YouTube vise à maximiser l'engagement des utilisateurs, de nombreux auteurs se demandent donc dans quelle mesure le RS de YouTube recommande les contenus borderline ou extrêmes [11] [10].

4.2 Le conspirationnisme et les echo chambers sur YouTube

D'abord, certains auteurs se sont intéressés aux recommandations de vidéos conspirationnistes [11]. Nous parlons ici d'un contenu borderline ou favorisant la désinformation des utilisateurs, telles que les exemples cités par YouTube dans une déclaration publique [27] : des vidéos défendant que la terre est plate, énonçant un faux remède miracle pour une maladie grave ou faisant des fausses déclarations sur des événements historiques comme le 11 septembre. Afin d'estimer le pourcentage de recommandations de ce type de contenu, les auteurs ont réalisé une analyse empirique sur

plus de 8 millions de recommandations du Up next panel sur 15 mois. Pour cela, ils ont collecté quotidiennement les recommandations à partir des vidéos les plus récentes publiées par un ensemble de plus de 1000 chaînes d'actualités et d'information les plus populaires du monde, et ont ensuite déterminé la probabilité que la vidéo soit conspirationniste via un modèle de classification binaire. La Figure 12 en montre les résultats, avec une estimation du pourcentage de vidéos conspirationnistes recommandées par YouTube sur les chaînes d'information (Raw Frequency), ainsi qu'une version pondérée de cette estimation, qui tient compte de la popularité de la vidéo source, vidéo à partir de laquelle toutes les recommandations sont collectées (Weighted Frequency).



Longitudinal trends of conspiratorial recommendations from informational channels on YouTube, in which each data point corresponds to a rolling seven day average. The **raw frequency** is an estimate of the percentage of conspiratorial recommendations obtained by weighting all recommendations classified as conspiratorial by their likelihood. This frequency represents the propensity of the YouTube algorithm to recommend conspiratorial content. The **weighted frequency** is an estimate of the percentage of conspiratorial weighted by the number of views of the source video. The **three dashed and dotted lines** correspond to the raw frequency for the top three topics: (1) Alternative Science and History, (2) Prophecies and Online Cults, and (3) QAnon, Deepstate, and New World Order (see Table 2). The **dotted vertical lines** represent the three YouTube announcements related to their efforts to fight conspiratorial content, on January 25th, June 5th and Dec 3rd of 2019.

Figure 12 : estimation du pourcentage de vidéos conspirationnistes recommandées par YouTube sur les chaînes d'information, entre octobre 2018 et février 2020 [11]

Les auteurs remarquent un boom des recommandations de vidéos conspirationnistes à la fin de 2018. On peut voir qu'au maximum, en décembre 2018, près de 10% des recommandations faites dans le Up next panel sur les chaînes d'informations sont des vidéos conspirationnistes, et 6% des recommandations lorsqu'on tient compte de la popularité de la vidéo source. Nous pouvons remarquer une baisse de cette tendance à partir d'avril 2019, jusqu'à 3% des recommandations en juin 2019.

Trois thèmes principaux ressortent de ces vidéos. Le premier concerne les alternatives en sciences et histoire, par exemple, des vidéos réfutant la théorie de l'évolution, ou encore des vidéos avançant l'idée que le développement durable est une arnaque propagée par l'élite dirigeante [25]. Le deuxième sujet principal est celui des prophéties et les cultes en ligne, telles que les affirmations selon lesquelles le monde touche à sa fin ou que les catastrophes naturelles et les événements politiques ont des causes religieuses. Le troisième sujet principal concerne les conspirations politiques, tel que des vidéos qui défendent que les

médias agissent contre les intérêts des Etats-Unis. A l'inverse, les auteurs remarquent que peu de vidéos conspirationnistes traitent des sujets cités par YouTube dans leur déclaration publique. Il en va de même pour les sujets très médiatisés comme les théories alternatives sur l'assassinat de JFK ou les vidéos conspirationnistes autour de la covid-19. Finalement, les auteurs suggèrent que les sujets très médiatisés font l'objet d'un examen plus approfondi, tandis que d'autres conspirations sont encore régulièrement recommandées. Selon eux, YouTube est disposé à cibler des problèmes spécifiques efficacement et en temps opportun.

Ensuite, il convient d'aborder les chambres d'écho ou bulles informationnelles. Ces termes désignent une situation où un *recommender system* expose une personne à un contenu similaire aux vidéos précédemment regardées, conduisant ainsi le spectateur à un état d'isolement informationnel. Les auteurs dont nous avons parlé précédemment ont montré qu'il y a une corrélation positive claire entre la probabilité de conspiration de la vidéo source et la probabilité de conspiration de la vidéo recommandée [11]. Mais il convient de rappeler qu'il est attendu d'un RS qu'il recommande du contenu similaire aux vidéos déjà recommandées, d'autant que les utilisateurs s'engagent de préférence avec des contenus conformes à leur vision du monde [28]. Si les vidéos conspirationnistes semblent bénéficier de chambres d'écho, il est difficile, selon les auteurs, de dire si cette exposition sélective est plus prononcée pour le contenu conspirationniste que pour les autres catégories. Ainsi, d'autres auteurs se sont penchés sur la possible existence d'*echo chambers* sur du contenu commercial. Si ce phénomène se vérifie, les echo chambers représenteraient un potentiel commercial, puisque les entreprises pourraient voir leurs vidéos promouvant leur marque davantage recommandées à un utilisateur [9]. Pour cela, les auteurs ont mené deux études empiriques.

La première étude a consisté à demander à 78 personnes via la plateforme de crowdsourcing M-Turk, de regarder 10 vidéos caritatives très populaires (vidéos sources) de 20 organismes caritatifs, et en enregistrant la prochaine vidéo recommandée par YouTube (vidéo recommandée). Le contenu des recommandations a été analysé par les auteurs. Selon eux, dans 43 % des cas, le RS recommande une vidéo de la même association caritative que la vidéo source, et dans 41 % des cas, l'algorithme recommande des vidéos qui n'ont aucun rapport avec les organisations caritatives ou le sujet de la vidéo principale. La seconde étude a consisté à collecter les données en déconnectant les comptes YouTube, c'est-à-dire sans profil utilisateur, et en récoltant les 5 prochaines recommandations de vidéos caritatives très populaires de 100 organismes caritatifs. Cette fois, les auteurs ont montré que cette fois dans 15 % des cas, le RS recommande une vidéo de la même association caritative que la vidéo source. Et dans 44,6 % des cas, les utilisateurs se voient recommander une vidéo sur un sujet complètement différent.

Ces deux études montrent que sur les vidéos d'organismes caritatifs, l'absence de profil utilisateur rend moins probable l'apparition d'une chambre d'écho. Les auteurs ont également énoncé que c'est la popularité de la vidéo source qui pourrait potentiellement conduire à la création d'une chambre d'écho, puisque des vidéos caritatives plus populaires conduisent à d'autres recommandations de la même association caritative. Finalement, les recommandations ne sont pas systématiquement sur des contenus d'une même association caritative ou sur un même sujet. Il est peu probable que les institutions caritatives bénéficient de chambres d'écho similaires à celles constatées sur les contenus

conspirationnistes [9]. Intéressons-nous à la modération de YouTube sur les contenus évoqués ci-dessus.

4.3 La modération de YouTube

D'abord, YouTube a des normes communautaires, dont l'infraction entraîne la suppression du contenu. Pour ces contenus, YouTube a annoncé plusieurs politiques. Dès 2011 déjà, l'entreprise énonce avoir créé des classificateurs pour identifier les vidéos racées ou violentes et les empêcher d'être recommandées : "we built classifiers to identify videos that were racy or violent" [12]. En 2015 et 2017 YouTube déclare avoir supprimé les vidéos incluant des mineurs dans des situations à risque et assuré que son système de recommandation soit équitable pour les communautés marginalisées. Puis l'entreprise a décidé de modérer les contenus favorisant la désinformation problématique et les contenus borderlines, c'est-à-dire le contenu qui se rapproche, mais qui ne viole pas tout à fait les règles communautaires, telles que les vidéos conspirationnistes. YouTube met en place des classificateurs pour identifier si une vidéo est "authoritative" ou "borderline". Pour cela, des *human evaluators* sont formés pour évaluer la qualité des informations de chaînes ou vidéos, en répondant à certaines questions clés : le contenu tient-il sa promesse ou atteint-il son objectif ? Quel type d'expertise est nécessaire pour atteindre l'objectif vidéo ? Quelle est la réputation de l'orateur dans la vidéo et de la chaîne sur laquelle elle est diffusée ? Le contenu est-il principalement destiné à être satirique ? Plus le score à ces réponses est élevé, plus la vidéo est promue en termes de contenu d'actualités et d'informations [12], et les scores sont utilisés pour entraîner des modèles. Si une vidéo est classée comme "borderline" elle est rétrogradée des recommandations. En juin 2019, YouTube déclare que ses efforts avaient entraîné une réduction de plus de 50% du temps de visionnage de vidéos conspirationnistes [26]. En décembre 2019, YouTube met à jour ce chiffre à 70%.

Les auteurs dont nous avons parlé sur le conspirationnisme affirment, au vu de l'analyse empirique, que YouTube a bien appliqué sa politique et a réduit massivement les recommandations de contenu conspirationnistes. Mais malgré cette baisse générale, le volume global de contenus complotistes recommandés par YouTube reste relativement élevé selon les auteurs. Pourtant, ils affirment que au vu de la quantité de données collectées et des ressources technologiques et humaines de YouTube, l'entreprise est en mesure de détecter les contenus conspirationnistes avec une grande précision : "Given the massively superior data, labelling and computational resources available to the company, we can affirm that YouTube is technically capable of detecting conspiratorial topics with high accuracy". D'autant qu'aucuns contenus conspirationnistes autour de la covid-19 n'ont été détectés, les auteurs considèrent que décider de ce qu'il ne faut pas recommander est donc une question de politique plus que de technologie pour YouTube [11].

Si YouTube semble aborder la modération du contenu borderline de type désinformation, rien n'est expliqué sur la modération du contenu borderline de type clickbait depuis l'introduction du watch-time en 2012. Le clickbait est une stratégie de marketing de contenu qui vise à publier des titres (et vignettes sur YouTube) sensationnels, pour inciter les utilisateurs à regarder un contenu. En revanche, Mark Zuckerberg déclare en 2018 que Facebook s'est également concentré sur le clickbait : "The category we're most focused on is click-bait and misinformation" [5]. De nombreux auteurs proposent des outils

technologiques de détection du clickbait [30][31][32], et certains avancent le fait que le moteur de recommandation YouTube ne prendrait pas en compte le clickbait [29].

Finalement, les plateformes doivent faire face à des contenus extrêmes et borderlines, parfois alimentés par des echo chambers. Cela rend la modération difficile. D'abord, les plateformes doivent réussir à donner la parole à tout le monde, tout en maintenant la sécurité et en évitant l'extrémisme et la désinformation. Dans un tel contexte plusieurs problématiques se posent : Où sont les limites de ce que les gens peuvent exprimer ? Quels contenus bloquer ? Qui devrait décider de ces politiques et prendre les décisions d'application ? Comme l'évoque Mark Zuckerberg, il n'y a pas d'accord général sur la bonne approche, et les gens arrivent souvent à des conclusions différentes sur les réponses à ces problématiques. D'autant que les normes culturelles ne sont pas les mêmes selon les pays, et qu'elles évoluent dans le temps. Il conclut ainsi : "Il y aura toujours des problèmes. Ce ne sont pas des problèmes que l'on résout, mais des solutions que l'on améliore continuellement. Tout comme une société libre aura toujours des crimes. On n'attend pas du gouvernement qu'il élimine tous les crimes, mais qu'il les gère et les réduise efficacement. Notre communauté fera toujours face à sa part d'abus. Notre travail consiste à limiter les utilisations abusives, à nous améliorer constamment au fil du temps et à garder une longueur d'avance sur les nouvelles menaces"² [5].

5. Transparence et Régulation

Nous l'avons vu, l'échelle particulièrement importante des grandes plateformes numériques telles que Facebook ou Youtube créent des défis de modération, et posent ainsi la question de responsabilité des contenus recommandés. De nombreux auteurs considèrent les plateformes numériques responsables du contenu qu'elles recommandent, et estiment ainsi qu'elles doivent en contrôler les contenus. D'autres rappellent l'importance de la liberté d'expression et de la neutralité du web. Dans cet environnement complexe où des acteurs privés assurent une grande distribution de l'information notamment via des systèmes de recommandation, comment réguler ?

5.1 La régulation européenne des services en ligne

La directive européenne sur le commerce électronique de 2000 (2000/31/CE1) fournit le régime de base applicable aux services numériques. Elle prévoit la liberté de fournir des services électroniques et la liberté d'établissement, ainsi que l'interdiction de surveillance généralisée des contenus et de recherche active, de la part des prestataires de services de la société de l'information, de contenus ou activités illicites. Cette directive s'est traduite en France par la loi confiance dans le numérique (LCEN), qui crée deux régimes de responsabilité, l'un pour le créateur du contenu, et l'autre pour l'hébergeur du contenu. La directive européenne énonce pour les hébergeurs de contenu un régime de responsabilité

² Traduit de l'anglais : "There will always be issues. These are not problems you fix, but issues where you continually improve. Just as a free society will always have crime and our expectation of government is not to eliminate all crime but to effectively manage and reduce it, our community will also always face its share of abuse. Our job is to keep the misuse low, consistently improve over time, and stay ahead of new threats."

limitée. Selon ce régime, un hébergeur ne peut être tenu pour responsable des contenus et activités illicites présents sur ses services, à condition qu'il n'ait pas eu connaissance de leur présence et de leur caractère illicite, ou que, en ayant eu effectivement connaissance, il ait agi "promptement" pour les retirer ou les rendre inaccessibles [34] [35]. Ce régime de responsabilité limitée visait à favoriser l'innovation.

Mais, comme l'évoque la Commission européenne, depuis l'adoption de cette directive, de nouveaux services numériques sont apparus et ont modifié la vie quotidienne des citoyens de l'Union européenne en façonnant et transformant leur façon de communiquer, de se connecter, et de consommer [33]. En effet, lors de l'établissement de la directive sur le commerce électronique, Amazon ne vendait encore que des livres, Google n'existait que depuis deux ans, et Twitter, Tiktok, Instagram, Facebook ou LinkedIn n'existaient pas. La consommation des services numériques s'est largement répandue, puisqu'en 2018, 70% des citoyens européens se déclarent utilisateurs réguliers des réseaux sociaux. Cette utilisation accrue a provoqué, comme évoqué précédemment, une augmentation du nombre de contenus illicites. La Commission Européenne énonce que le nombre de signalements d'images pédopornographiques en ligne est passé de 23 000 en 2010 à plus de 725 000 en 2019 [35]. Ces évolutions ont nécessité l'ajout de nouvelles directives. D'abord, la directive révisée sur les services de médias audiovisuels de 2018. Elle impose davantage d'obligations aux plateformes de partage de vidéos pour protéger le public contre les contenus illégaux et les mineurs contre les contenus préjudiciables. Ces règles sont renforcées par des règles plus strictes pour quatre types de contenus pour lesquels l'illégalité a été harmonisée au niveau de l'Union Européenne : la directive contre le terrorisme, la directive sur les abus et l'exploitation sexuels d'enfants, le cadre de lutte contre le racisme et la directive sur le droit d'auteur dans le marché unique numérique. Ces réglementations sont complétées par des initiatives d'autorégulation mises en place par les plateformes elles-mêmes. Le cadre européen encourage ces initiatives comme lors de l'élaboration d'un code de conduite européen sur la lutte contre les discours haineux illégaux en ligne et les bonnes pratiques contre la désinformation [35].

Plusieurs États membres ont adopté des règles nationales en matière de modération de contenu tel que la loi allemande NetzDG sur les contenus illicites. Cependant, la compatibilité juridique de ces initiatives avec le cadre de l'UE n'est parfois pas claire et la multiplication des législations nationales a créé une fragmentation des lois et des pratiques concernant la modération de contenu dans les états membres [36]. Face à ces problématiques, le 15 décembre 2020, la Commission européenne publie un projet de texte qui a pour objet de réguler les plateformes numériques : le Digital Services Act (DSA), parallèlement au Digital Markets Act (DMA) qui traite de la concurrence au sein des marchés numériques. Le projet de texte vise à réviser le cadre réglementaire de l'UE sur la modération de contenu en ligne, en renforçant la responsabilité des plateformes en ligne pour garantir un Internet plus sûr [36]. Le DSA formule des obligations pour les différents acteurs en ligne (Annexe 1) selon leur rôle, leur taille, et leur impact sur l'écosystème en ligne. Sont ainsi distingués :

- les services intermédiaires : fournisseurs d'accès à internet et bureaux d'enregistrement de noms de domaine
- les services d'hébergement : les services de cloud et d'hébergement en ligne
- les plateformes en ligne : réunissant les vendeurs et consommateurs (réseaux sociaux, marketplaces etc.)

- les très grandes plateformes en ligne : atteignant plus de 10 % des 450 millions de consommateurs en Europe. (Section 4)

5.2 Le projet européen de régulation sur les systèmes de recommandation

Intéressons-nous à quelques obligations énoncées par la Commission Européenne dans le DSA, qui sont des solutions aux défis des plateformes précédemment démontrés.

La Commission énonce une obligation dans le cas où de très grandes plateformes en ligne utilisent des systèmes de recommandation (article 29). Elle traduit l'importance des technologies de recommandation : “[les systèmes de recommandation] peuvent avoir une incidence significative sur la capacité des bénéficiaires à récupérer les informations en ligne et à interagir avec elles. Ils jouent également un rôle important dans l’amplification de certains messages, la diffusion virale de l’information et la stimulation du comportement en ligne”. La Commission met en place plus de transparence via trois moyens :

- une obligation de garantir que les utilisateurs sont informés de manière appropriée sur les paramètres pris en compte dans le système de recommandation. Pour cela, les plateformes doivent dire clairement dans leurs conditions générales quels sont les principaux paramètres utilisés dans leurs systèmes de recommandation. L’objectif est que les bénéficiaires comprennent clairement comment l’information est hiérarchisée à leur intention.
- une obligation de veiller à ce que les utilisateurs puissent avoir d’autres options concernant les principaux paramètres de recommandation. Ainsi, les plateformes doivent aussi expliquer dans leurs conditions générales de manière claire, les options dont disposent les utilisateurs pour modifier ou influencer ces principaux paramètres du système de recommandation. Parmi ces options doit se trouver une option qui ne relève pas du profilage.
- une obligation de mettre en place une fonctionnalité aisément accessible sur leur interface en ligne permettant à l’utilisateur de sélectionner et de modifier à tout moment son option favorite.

Ensuite, la Commission oblige les grandes plateformes à montrer qu’elles respectent bien toutes les obligations énoncées dans le chapitre III qui visent au maintien d’un environnement en ligne sûr et transparent. Pour cela, elle utilise deux moyens différents. Le premier consiste en la formulation d’audits externes et indépendants, au frais des plateformes, au minimum une fois par an, pour évaluer le respect des obligations (article 28). Le second concerne une obligation de partage des données qui permettent d’évaluer le fonctionnement et tester les systèmes algorithmiques de modération de contenu, les systèmes de recommandation ou les systèmes de publicité (article 31).

Sur ce deuxième point, la Commission reconnaît l’importance des études réalisées par les chercheurs, qui participent à la transparence et à la correction des asymétries d’information. Elle s’exprime : “Les études réalisées par des chercheurs sur l’évolution et la gravité des risques systémiques en ligne sont particulièrement importantes pour corriger les asymétries d’information et établir un système résilient d’atténuation des risques, informer les plateformes en ligne, les coordinateurs pour les services numériques, les autres autorités compétentes, la Commission et le public”. Les auteurs précédemment cités sur les contenus conspirationnistes défendent eux aussi l’importance de ce travail de transparence

nécessaire. En effet l'article écrit par ces auteurs a permis la mise en action puisqu'il a été cité par le congrès américain dans une lettre envoyée aux CEOs de Google et YouTube [11] [37]. Ainsi, le Commission Européenne énonce que le DSA fournit un cadre permettant de garantir aux chercheurs agréés la possibilité d'accéder aux données provenant des très grandes plateformes en ligne. Elle précise tout de même que cet accès aux données doit être proportionné et doit : "permettre de protéger les droits et les intérêts légitimes, y compris les secrets commerciaux et autres informations confidentielles, de la plateforme et de toute autre partie concernée, y compris les bénéficiaires du service" [38].

5.3 La régulation chinoise des systèmes de recommandation

Le 31 décembre 2021, la Cybersecurity Administration of China (CAC) adopte un règlement sur l'utilisation des *recommender systems* : le "Internet Information Service Algorithmic Recommendation Management Provisions". Cette réglementation, particulièrement fournie et exigeante en matière de transparence et de contrôle des données par les utilisateurs, est inédite. Aucune autre régulation des *recommender systems* n'est aussi complète [39]. En vertu de la nouvelle réglementation, les opérateurs d'algorithmes devront, à partir de l'entrée en vigueur le 1 mars 2022, mettre à jour leur technologie pour se conformer aux nouvelles exigences techniques. Le Internet Information Service Algorithmic Recommendation Management Provisions se compose de 30 articles dont l'infraction de certains articles peut donner lieu à une amende entre 5 000 à 30 000 yuans. D'autres articles constituent davantage un code éthique pour des systèmes de recommandations davantage respectueux du bien-être des utilisateurs.

D'abord, le règlement veille à ce que les utilisateurs aient davantage de contrôle sur le système de recommandation. La CAC demande aux plateformes de fournir aux utilisateurs des options de recommandations qui ne reposent pas sur le profil utilisateur, ou une option pour désactiver les services de recommandation [40]. Cette disposition s'accompagne de la préconisation de mettre en place, sur la page d'accueil, de mécanismes robustes d'intervention manuelle, permettant aux utilisateurs de choisir les contenus en toute autonomie. La CAC demande d'arrêter immédiatement de fournir des services de recommandation lorsqu'un utilisateur choisit de désactiver le service de recommandation. Elle préconise aussi de fournir aux utilisateurs la possibilité de sélectionner ou de supprimer des mots-clés de leur profil utilisateur pour les services de recommandation d'algorithmes. Enfin, si l'application de l'algorithme affecte de manière significative les droits et intérêts des utilisateurs, l'entreprise devra fournir une explication aux utilisateurs et assumer la responsabilité correspondante. Ces dispositions vont nécessiter la création d'outils permettant aux utilisateurs de supprimer activement les mots-clés utilisés par l'algorithme de recommandation, aucune autre régulation ne prévoit ce type de disposition [39].

Ensuite, la CAC souhaite promouvoir les "algorithms for good". Pour cela, l'article 6 prévoit une optimisation du système de recommandation pour diffuser une "énergie positive", faire progresser l'utilisation des algorithmes vers le haut et dans le sens du bien, et "soutenir les orientations des valeurs dominantes". L'article 8 complète cette idée avec une interdiction de mettre en place de modèles algorithmiques contraires à l'ordre public et aux bonnes mœurs, tels qu'en conduisant les utilisateurs à la dépendance ou à la consommation à haute valeur ajoutée.

Selon certains auteurs, cette réglementation chinoise contient à la fois des dispositions qui relèvent du bon sens, telles que les mesures visant à assurer la sécurité des données des utilisateurs, de modérer le contenu illicite, etc. Lorsque d'autres éléments sont plus spécifiques à l'environnement d'information contrôlé de la Chine, tel que la mesure visant à soutenir les orientations des valeurs dominantes [41]. Malgré tout, en ressortent des dispositions innovantes, même si certaines questions persistent : Comment Douyin, la version chinoise de Tiktok, appliquera-t-elle la disposition visant à ne pas créer de la dépendance chez les utilisateurs lorsque son algorithme repose sur une optimisation des recommandations visant à garder l'utilisateur sur la plateforme ? Que sont les "mots-clés" possiblement désactivables pour plus de contrôle sur le système de recommandation et suffisent-ils à avoir plus de contrôle ? Que serait Douyin ou d'autres plateformes de ce type si l'on désactive la personnalisation ? Si certaines de ces nouvelles dispositions fonctionnent bien pour la Chine, elles pourront faire l'objet d'une adoption plus large [41].

Conclusion

Le *recommender system* de YouTube influence la circulation de l'information et a pour objectif de maximiser l'engagement de l'utilisateur via des recommandations qui lui sont adaptées. Pourtant, les décisions prises par le système de recommandation sont largement non supervisées et opaques pour le public [11], créant une asymétrie d'information entre l'utilisateur ou le créateur de contenu et l'entreprise. Une bonne manière de réduire cette asymétrie et de responsabiliser les plateformes sur leurs décisions serait de favoriser la transparence sur le comportement de leurs systèmes de recommandations. Le proposition de texte du Digital Services Act est un premier pas en ce sens. Mais comme l'exprime YouTube, l'échelle et l'évolution constante du système de recommandation rend difficile cette transparence : "Il évolue constamment, apprenant chaque jour à partir de plus de 80 milliards d'informations [...] C'est pourquoi fournir plus de transparence n'est pas aussi simple que d'énumérer une formule de recommandations, mais implique de comprendre toutes les données qui alimentent notre système³" [12]. Il convient donc de se pencher sur l'explicabilité des RS et formuler un protocole technique et expérimental permettant de surveiller le fonctionnement du *recommender system* de YouTube.

³ Traduit de l'anglais : "It's constantly evolving, learning every day from over 80 billion pieces of information we call signals. That's why providing more transparency isn't as simple as listing a formula for recommendations, but involves understanding all the data that feeds into our system"

Annexe 1 :

Nouvelles obligations

	Services intermédiaires (obligations cumulatives)	Services d'hébergement (obligations cumulatives)	Plateformes en ligne (obligations cumulatives)	Très grandes plateformes (obligations cumulatives)
Communication d'informations sur la transparence	*	*	*	*
Obligations d'adopter des conditions d'utilisation respectant les droits fondamentaux	*	*	*	*
Coopération avec les autorités nationales à la suite d'injonctions	*	*	*	*
Points de contact et, le cas échéant, représentant légal	*	*	*	*
Obligations de notification et d'action, et obligation de fournir des informations aux utilisateurs		*	*	*
Mécanisme de réclamation et de recours et règlement extrajudiciaire des litiges			*	*
Signaleurs de confiance			*	*
Mesures contre les signalements et contre-signalements abusifs			*	*
Examen des références des fournisseurs tiers («KYBC»)			*	*
Transparence de la publicité en ligne pour les utilisateurs			*	*
Signalement des infractions pénales			*	*
Obligations en matière de gestion des risques et responsable de la conformité				*
Audit des risques externes et responsabilité publique				*
Transparence des systèmes de recommandation et choix des utilisateurs pour l'accès à l'information				*
Partage des données avec les autorités et les chercheurs				*
Codes de conduite				*
Coopération en matière de réaction aux crises				*

Bibliographie

- [1] **Dietmar Jannach, Markus Zanker, Alexander Felfernig, Gerhard Friedrich.** *Recommender Systems: An Introduction*. Cambridge University Press, 2010.
- [2] **Paul Covington, Jay Adams, Emre Sargin.** “Deep Neural Networks for YouTube Recommendations”, the 10th ACM Conference, September 2016, DOI:10.1145/2959100.2959190
- [3] **Zhe Zhao, Lichan Hong, Li Wei, Jilin Chen, Aniruddh Nath, Shawn Andrews, Aditee Kumthekar, Maheswaran Sathiamoorthy, Xinyang Yi, Ed Chi.** “Recommending What Video to Watch Next: A Multitask Ranking System”, the 13th ACM Conference on Recommender Systems, September 2019
- [4] **Lu Jiang, Yajie Miao, Yi Yang, Zhenzhong Lan, Alexander G. Hauptmann.** “Viral Video Style: A Closer Look at Viral Videos on YouTube”, Proceedings of International Conference on Multimedia Retrieval, April 2014, DOI:10.1145/2578726.2578754
- [5] **Mark Zuckerberg.** “A Blueprint for Content Governance and Enforcement”, Facebook [En ligne, consulté le 15.02.2022]
- [6] **Rahwan, I., Cebrian, M., Obradovich, N. et al.** Machine behaviour. *Nature* 568, 477–486 (2019). <https://doi.org/10.1038/s41586-019-1138-y>
- [7] **Xinyang Yi, Ji Yang, Lichan Hong, Derek Zhiyuan Cheng, Lukasz Heldt, Aditee Kumthekar, Zhe Zhao, Li Wei, and Ed Chi.** Sampling-bias-corrected neural modeling for large corpus item recommendations, In Proceedings of the 13th ACM Conference on Recommender Systems (RecSys '19), 2019, Association for Computing Machinery, New York, NY, USA, 269–277. DOI:<https://doi.org/10.1145/3298689.3346996>
- [8] **Gunhaeng Lee.** “Recommender systems and the value of user data”, September 2021
- [9] **Lambrecht, Anja and Sen, Ananya and Tucker, Catherine E. and Wiertz, Caroline Wiertz.** Algorithmic Recommendations and Earned Media: Investigating Product Echo Chambers on YouTube (October 27, 2021). Available at SSRN: <https://ssrn.com/abstract=3951425> or <http://dx.doi.org/10.2139/ssrn.3951425>
- [10] **Manoel Horta Ribeiro, Raphael Ottoni, Robert West, Virgílio A. F. Almeida, and Wagner Meira.** 2020. Auditing radicalization pathways on YouTube. In Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency (FAT* '20). Association for Computing Machinery, New York, NY, USA, 131–141. DOI:<https://doi.org/10.1145/3351095.3372879>
- [11] **Faddoul, Marc, Guillaume Chaslot and Hany Farid.** “A Longitudinal Analysis of YouTube's Promotion of Conspiracy Videos.” ArXiv abs/2003.03318 (2020): n. pag.
- [12] “On YouTube’s recommendation system”, Youtube Blog [En ligne, consulté le 15.02.2022]

[13] **Baptiste Rocca**. "Introduction to recommender systems", towards data science, Jun 2019 [En ligne, consulté le 15.02.2022]

[14] **Justine Bachelot** (Youtube). Frames Festival, 2021 [En ligne, consulté le 15.02.2022]
https://github.com/iciamyplant/Youtube_algorithm_analyse/blob/master/Presentation1FramesYouTube.pdf

[15] **Davidson, James & Liebald, Benjamin & Liu, Junning & Nandy, Palash & Vleet, Taylor & Gargi, Ullas & Gupta, Sujoy & He, Yu & Lambert, Michel & Livingston, Blake & Sampath, Dasarathi**. (2010). The YouTube video recommendation system. 293-296. 10.1145/1864708.1864770.

[16] **Yi, Xinyang & Yang, Ji & Hong, Lichan & Cheng, Derek & Heldt, Lukasz & Kumthekar, Aditee & Zhao, Zhe & Wei, Li & Chi, Ed**. (2019). Sampling-bias-corrected neural modeling for large corpus item recommendations. 269-277. 10.1145/3298689.3346996.

[17] **Jannach, Dietmar & Jugovac, Michael**. (2019). Measuring the Business Value of Recommender Systems. ACM Transactions on Management Information Systems. 10. 1-23. 10.1145/3370082.

[18] **Xavier Amatriain and Justin Basilico**. "Netflix Recommendations: Beyond the 5 stars (Part 1)", The Netflix Tech Blog, 2012, [En ligne, consulté le 15.02.2022]

[19] **Katukuri, Jayasimha & Könik, Tolga & Mukherjee, Rajyashree & Kolay, Santanu**. (2014). Recommending Similar Items in Large-scale Online Marketplaces. 10.13140/2.1.3259.2646.

[20] **Jenna Romaine**. "Google is dethroned as world's most popular website", Changing America, December 2021 [En ligne, consulté le 15.02.2022]

[21] "YouTube Now: Why We Focus on Watch Time", Youtube Blog [En ligne, consulté le 15.02.2022]

[22] **Gómez-Uribe, Carlos & Hunt, Neil**. (2015). The Netflix Recommender System. ACM Transactions on Management Information Systems. 6. 1-19. 10.1145/2843948.

[23] "Quelles sont les sources de revenus de YouTube ?", Youtube Blog [En ligne, consulté le 15.02.2022]

[24] "YouTube's Product Chief on Online Radicalization and Algorithmic Rabbit Holes", New York Times, 2019 [En ligne, consulté le 15.02.2022]

[25] **Nicolas Martin**. "Peut-on nier la théorie de l'évolution ?", Les idées claires, France Culture, 2018

- [26] **Louise Matsakis**. "YouTube Will Link Directly to Wikipedia to Fight Conspiracy Theories", Wired, 2018 [En ligne, consulté le 15.02.2022]
- [27] "Continuing our work to improve recommendations on YouTube", Youtube Blog [En ligne, consulté le 15.02.2022]
- [28] **Schwind, Christina & Buder, Jürgen**. (2012). Reducing confirmation bias and evaluation bias: When are preference-inconsistent recommendations effective - And when not?. Computers in Human Behavior. 28. 2280–2290. 10.1016/j.chb.2012.06.035.
- [29] **S. Zannettou, S. Chatzis, K. Papadamou and M. Sirivianos**. "The Good, the Bad and the Bait: Detecting and Characterizing Clickbait on YouTube," 2018 IEEE Security and Privacy Workshops (SPW), 2018, pp. 63-69, doi: 10.1109/SPW.2018.00018.
- [30] **Potthast, Martin & Köpsel, Sebastian & Stein, Benno & Hagen, Matthias**. (2016). Clickbait Detection. 9626. 810-817. 10.1007/978-3-319-30671-1_72.
- [31] **Chakraborty, Abhijnan & Paranjape, Bhargavi & Kakarla, Sourya & Ganguly, Niloy**. (2016). Stop Clickbait: Detecting and preventing clickbaits in online news media. 9-16. 10.1109/ASONAM.2016.7752207.
- [32] **Biyani, Prakhar, Kostas Tsioutsoulis and John Blackmer**. "'8 Amazing Secrets for Getting More Clicks': Detecting Clickbaits in News Streams Using Article Informality." AAAI (2016).
- [33] **European Commission**. Proposal for a Regulation of the European Parliament and of the Council on a Single Market For Digital Services (Digital Services Act) and amending Directive 2000/31/EC
- [34] **Parlement européen et Conseil**. "directive sur le commerce électronique", Directive 2000/31/CE du 8 juin 2000 [En ligne, consulté le 15.02.2022]
- [35] **Sénat**. "Sur la proposition de législation européenne sur les services numériques (DSA)", 2022 [En ligne, consulté le 15.02.2022]
- [36] **European Parliament**. "Online Platforms' Moderation of Illegal Content Online" [En ligne, consulté le 15.02.2022], available at: www.europarl.europa.eu/supporting-analyses
- [37] Congress of the United States. Letter to YouTube and Google CEOs, January 2021, [En ligne, consulté le 15.02.2022], available at : https://malinowski.house.gov/sites/malinowski.house.gov/files/Letter%20to%20YouTube%20--%20Malinowski_Eshoo_final_0.pdf
- [38] **Commission Européenne**. "RÈGLEMENT DU PARLEMENT EUROPÉEN ET DU CONSEIL, relatif à un marché intérieur des services numériques (Législation sur les services numériques) et modifiant la directive 2000/31/CE", 2020, available at: <https://eur-lex.europa.eu/legal-content/fr/TXT/?qid=1608117147218&uri=COM%3A2020%3A825%3AFIN>

[39] **Arendse Huld.** “China Passes Sweeping Recommendation Algorithm Regulations”, China Briefing, 2022 [En ligne, consulté le 15.02.2022]

[40] **Helen Toner, Rogier Creemers, Graham Webster.** “Translation: Internet Information Service Algorithmic Recommendation Management Provisions (Draft for Comment)”, Stanford University Website, Aug. 2021 [En ligne, consulté le 15.02.2022]

[41] **Helen Toner, Helen Toner, Paul Triolo, Rogier Creemers.** “Experts Examine China’s Pioneering Draft Algorithm Regulations, Stanford University Website, Aug. 2021 [En ligne, consulté le 15.02.2022]

[42] **Chad Hurley.** “Y,000,000,000uTube”, Youtube Blog [En ligne, consulté le 15.02.2022] available at: <https://blog.youtube/inside-youtube/on-youtubes-recommendation-system/>

[43] “YouTube for Press”, Youtube Blog [En ligne, consulté le 15.02.2022] available at: <https://blog.youtube/press/>